

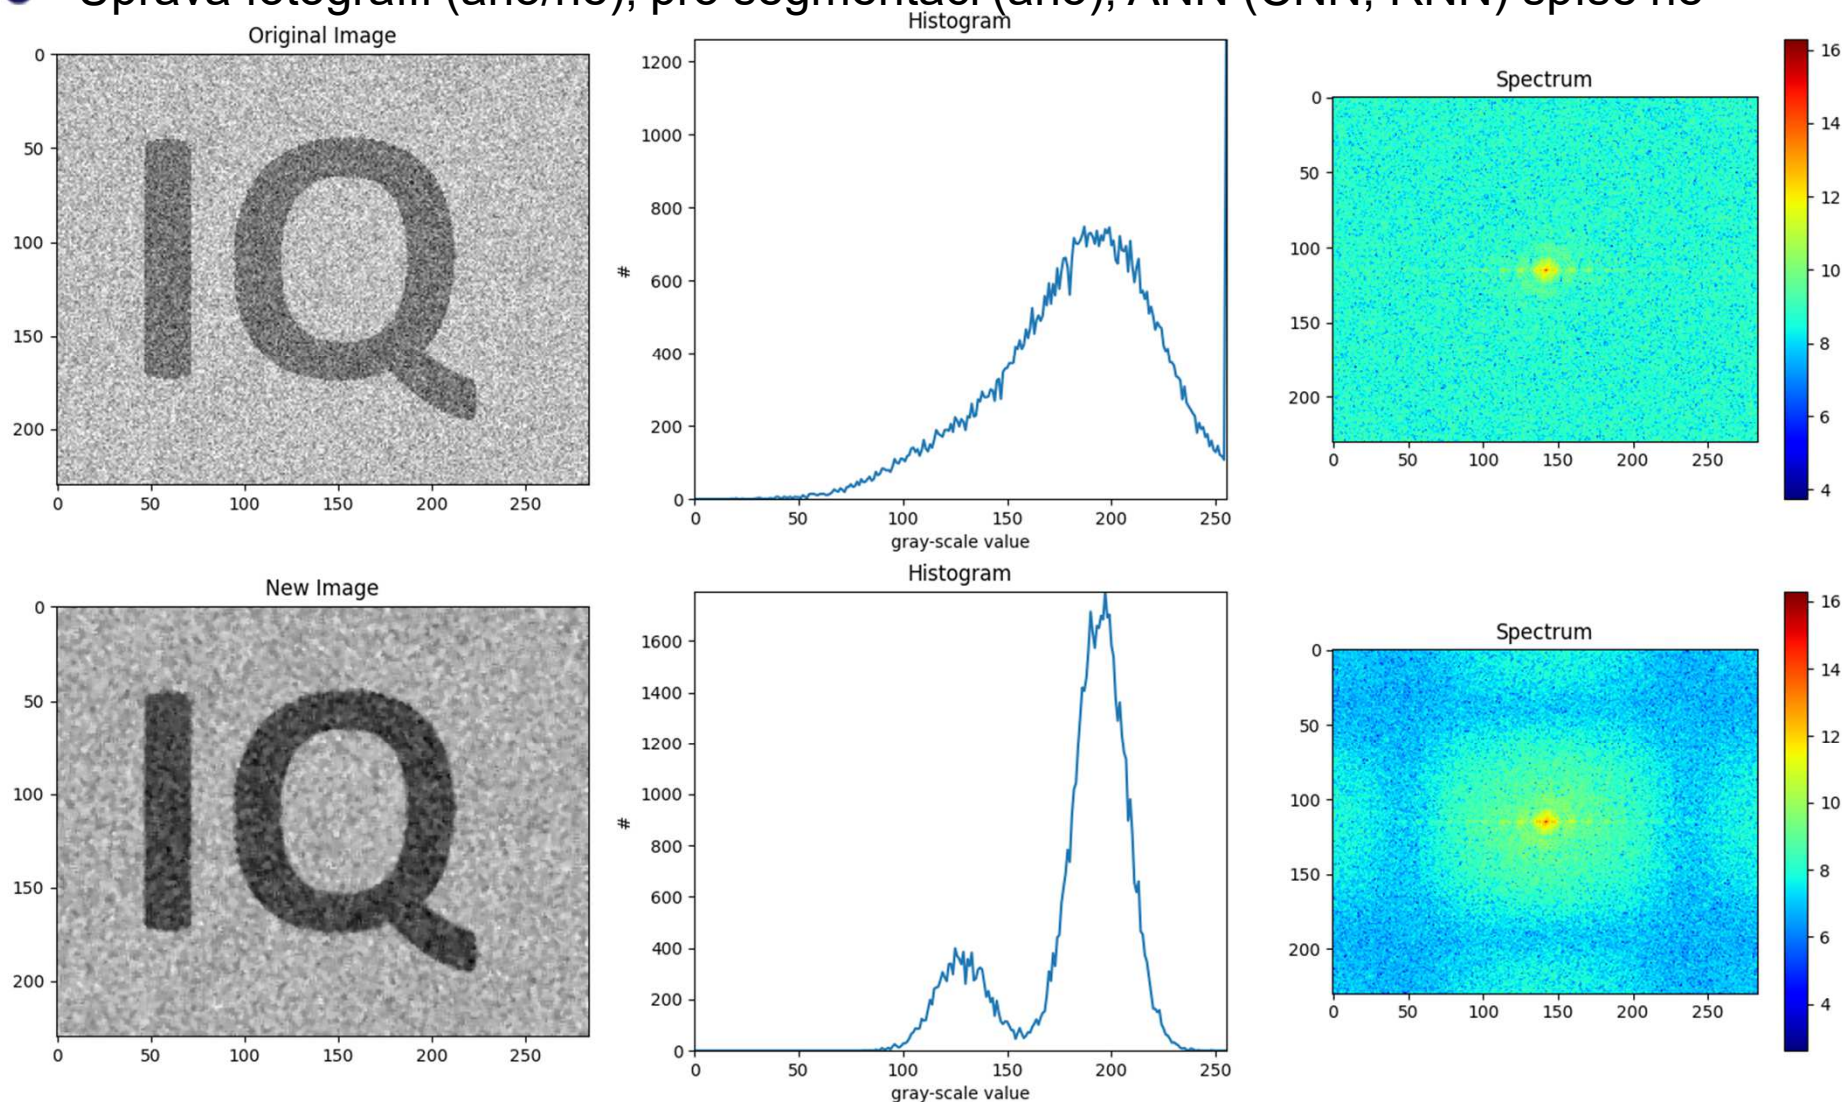
# Filtrace šumu a hledání hran v obraze

doc. Ing. Josef Chaloupka, Ph.D.



# Filtrace šumu – praktické využití

- Úprava fotografií (ano/ne), pro segmentaci (ano), ANN (CNN, RNN) spíše ne




# FILTRACE ŠUMU

- **Statistický princip filtrace šumu >>>**
- Aditivní šum  $v$  - na obrazové funkci nezávislý, nulová střední hodnota, směrodatná odchylka  $\sigma$   $n$ -násobné sejmutí statické scény za stejných podmínek
- Z každého obrazu stejný bod  $g_i(x,y)$ ,  $i = 1 \dots N$
- Odhad správné hodnoty:
$$g_s(x,y) = \frac{g_1(x,y) + \dots + g_n(x,y)}{n} + \frac{v_1 + \dots + v_n}{n}$$
- Nová směrodatná odchylka šumu:
$$\sigma_s = \sigma / \sqrt{n}$$
- Centrální limitní věta >>> velké náhodné výběry >>> rozdělení výběrových průměrů je blízké k normálnímu, původně ho mít nemusela
- Velký výběr (30) >>> statistika >>> interval spolehlivosti




# FILTRACE ŠUMU




obr. 01

...



obr. 25



# LOKÁLNÍ FILTRACE


- Malé okolí  $O$  reprezentativního pixelu
- **1. vyhlazování** >>> potlačení šumu a osamocených fluktuací hodnot obrazové funkce >>> **DP**
- **2. detekce hran** >>> gradientní operátory >>> odhad derivací obrazové funkce >>> **HP**
- 1 a 2 protiklad (lineární podoba) >>> nelineární metody, které vyhlazují a přitom jsou šetrné k hranám a detailům v obraze
- Lineární operace >>> lineární kombinaci hodnot vstupního obrazu  $f$  v malém okolí  $O$  reprezentativního pixelu  $(x,y)$

$$f(x,y) = \sum_{(m,n) \in O} h(x-m, y-n) \cdot g(m,n) \quad h \dots \text{konvoluční maska}$$

- Výhodná znalost >>> známé statistické parametry šumu
- Předzpracování (žádná nová informace  $S - H$  věta, potlačení nebo zvýraznění informace)
- Zlepšení informace >>> lepší pořízení
- Konvoluční filtry >>> hardwarová realizace

# LINEÁRNÍ METODY VYHLAZOVÁNÍ

- Nová hodnota reprezentativního bodu >>> lineární kombinace hodnot ve zkoumaném okolí >>> diskrétní konvoluce
- Lineární filtry** >>> různé váhy v lineární kombinaci, které jsou dány příslušnou konvoluční maskou  $h$  (dvojměrnou impulsní odezvou)




- Prostorově invariantní filtry (homogenní filtry) >>> chování filtru se nemění při změně polohy v obrázku >>> postupná konvoluce s malou maskou
- Linearita porušena >>> hodnota obrazové funkce (jas, intenzita) je nezáporná a omezená, obrazy jsou ohraničeny v prostoru
- Prostorová invariantnost jen pro omezené posuny konvolučních masek

# LINEÁRNÍ METODY VYHLAZOVÁNÍ

- **Metoda prostého průměrování** >>> nová hodnota jasu bodu (x,y) >>> aritmetický průměr původních jasů ve zvoleném okolí, konvoluční maska  $h$  pro okolí  $3 \times 3$ :

$$h = \frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} \quad \text{s váhováním bodů} \quad h = \frac{1}{10} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 1 \end{bmatrix}, \quad h = \frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$$







- **(-)** rozmazání hran, konvoluce >>> součin Fourierova obrazu 2-D signálu a Fourierova obrazu konvolučního filtru >>> filtrace DP
- Průměr >>> pomocná hodnota u některých nelineárních metod
- Nová hodnota reprezentativního bodu >>> lineární kombinace hodnot ve zkoumaném okolí >>> diskrétní konvoluce



# LINEÁRNÍ METODY VYHLAZOVÁNÍ

- **Metoda prostého průměrování**





# LINEÁRNÍ METODY VYHLAZOVÁNÍ

- **Separabilní filtry** >>> konvoluční masku v p-rozměrném okolí, obvykle  $p = 2$ ; 3 lze rozložit na součin jednorozměrných masek

$$\begin{bmatrix} 1 & 4 & 6 & 4 & 1 \\ 4 & 16 & 24 & 16 & 4 \\ 6 & 24 & 36 & 24 & 6 \\ 4 & 16 & 24 & 16 & 4 \\ 1 & 4 & 6 & 4 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 4 & 6 & 4 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 4 \\ 6 \\ 4 \\ 1 \end{bmatrix}$$

- Binomický 2D filtr rozměru  $5 \times 5$  (binomických čísel >>> součet dvou čísel v předchozím řádku Pascalova trojúhelníku)
- Pro výpočet konvoluce >>> 25 násobení a 24 sčítání pro každý pixel, separabilní filtr >>> 10 součinů a 8 součtů
- Pro 3D obrázek (např. z tomograf), konvoluční jádro rozměru  $9 \times 9 \times 9$ , pro každý voxel >>> 729 součinů a 728 součtů, separovatelný filtr >>> 27 součinů a 24 součtů na voxel

# LINEÁRNÍ METODY VYHLAZOVÁNÍ

- **Rekurzivní filtry** >>> invariantní >>> jako vstupní hodnoty pro konvoluci použity hodnoty vypočtené v předchozí poloze masky (jen její části, která je již naplněna novými hodnotami), pro 1D signál:

$$g'_n = h_0 g_n + \sum_{i=0}^r h_n g'_{n-i}$$

- V konvoluci se kombinují nefiltrované a filtrované hodnoty >>> zavedení zpětné vazby, fungují v jednom daném směru, pro uchování minulých hodnot signálů je potřebná paměť >>> dynamický systém
- U 1D mohou být nestabilní u 2D jsou stabilní vždy, jednodušší popis než u nerekurzivních filtrů, u 2D neexistuje přirozený směr (u 1D čas), preferovány filtry s 0 fázovým posunem (neposouvání hran)
- Složitá teorie a interpretace, zjednodušení >>> kaskádní řazení jednoduchých filtrů



# NELINEÁRNÍ METODY VYHLAZOVÁNÍ

- Částečné potlačení rozmazáváním hran
- V analyzovaném okolí  $O$  se snaží najít jen tu jeho část (oblast o zhruba konstantním jasu), do které reprezentativní bod patří



# NELINEÁRNÍ METODY VYHLAZOVÁNÍ





- **Filtace metodu rotující masky** >>> nerozmazává hrany, mírně ostří, maska čtverec  $3 \times 3$ , 8 poloh masky, v každé masce se spočte rozptyl jasů, vybere se maska s nejmenším rozptylem (homogenní okolí reprezentativního bodu), výsledná hodnota reprezentativního bodu - aritmetický průměr hodnot ve vybrané masce, rychle konverguje do stabilního stavu – závisí na velikosti masky



- Využití >>> oprava velkoplošných chyb bez vlivu na zbytek obrazu, jednoduché vyhlazení bez poškození hran.

# NELINEÁRNÍ METODY VYHLAZOVÁNÍ

## ● Filtrace metodu rotující masky




# NELINEÁRNÍ METODY VYHLAZOVÁNÍ

- **Statistické nelineárním filtry**
- Průměrování 8 x stejná hodnota, 1 x  $\infty$ , aritmetický průměr =  $\infty$ , je vychýlený
- Lineárním aproximací pomocí metody nejmenších čtverců - prokládání množiny bodů přímkou, jeden bod je vychýlený, aproximující přímka je vychýlená
- Robustní statistika >>> nalézt vychýlené hodnoty a vyloučit je
- Vyloučení maximální a minimální hodnoty
- Výběrové kvantily >>> např. medián  $M$  >>> hodnota, pro kterou je pravděpodobnost jevu  $x < M$  rovna jedné polovině
- Uspořádání vzestupně hodnoty jasu v lokálním okolí
- **Medián:** prvek, který je uprostřed této posloupnosti, výhodné masky  $3 \times 3$ ,  $5 \times 5$ , ...




# NELINEÁRNÍ METODY VYHLAZOVÁNÍ

- **Filtrování pomocí mediánu**







- Redukce rozmazání hran, potlačení impulsního šum
- (-) filtrace mediánem v obdélníkovém okolí >>> porušení tenkých čar a ostrých >>> používá se jiný tvar okolí:



# NELINEÁRNÍ METODY VYHLAZOVÁNÍ

## ● Filtrování pomocí mediánu



# DETEKCE HRAN

- Pro vnímání člověka jsou velmi důležitá místa v obraze, kde se náhle mění hodnota jasu >>> pixely >>> hrany
- Lokální předzpracování >>> hledání hran
- Hrana v obraze dána vlastnostmi obrazového elementu a jeho okolí
- Určení >>> rychlost změny hodnoty obrazové funkce  $f(x,y)$
- Studium změn funkce dvou proměnných >>> parciální derivace
- Změnu funkce udává její gradient (vektor  $\nabla$ ), určuje směr největšího růstu funkce (směr gradientu) a strmost tohoto růstu (velikost, modul gradientu)
- Hrany >>> pixely s velkým modulem gradientu




# DETEKCE HRAN

- Pro spojitou funkci  $f(x,y)$ :

$$|\nabla f(x,y)| = \sqrt{\left(\frac{\partial f}{\partial x}\right)^2 + \left(\frac{\partial f}{\partial y}\right)^2} \text{ velikost gradientu}$$

$$\Phi = \arg\left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}\right) \text{ směr gradientu}$$

úhel (v radiánech) mezi souřadnou osou  $x$  a radiusvektorem k bodu  $(x,y)$




- Odhad velikosti hrany (gradientu)  $\gg \gg$  všesměrový lineární Laplaceův operátor-Laplacián  $\nabla^2$ , vychází z druhých parciálních derivací


$$\nabla^2 g(x,y) = \frac{\partial^2 g(x,y)}{\partial x^2} + \frac{\partial^2 g(x,y)}{\partial y^2}$$

- Použití hran nalezených v obraze lokálními operátory pro hledání hranic objektů, pokud objekt odpovídá oblasti homogenního jasu
- Směr hrany  $\Phi$  se někdy definuje jako kolmý na směr gradientu  $\Psi \gg \gg$  hranové pixely se poté mohou spojovat do hranic


# DETEKCE HRAN




hrany: skoková



střechová



liniová



zašuměná

# DETEKCE HRAN

- Aproximace parciální derivace diferencemi:

$$\Delta_x g(x, y) = g(x, y) - g(x - n, y)$$

$$\Delta_y g(x, y) = g(x, y) - g(x, y - n)$$

- Symetricky (zanedbává vliv bodu x,y – moc se nepoužívá):

$$\Delta_x g(x, y) = g(x + n, y) - g(x - n, y)$$

$$\Delta_y g(x, y) = g(x, y + n) - g(x, y - n)$$

# DETEKCE HRAN

- Gradientní operátory:
- 1. operátory aproximují derivace pomocí diferencí, některé jsou invariantní vůči rotaci (Laplacián - konvoluce s jedinou maskou), pro jiné, aproximující první derivaci využití několika masek odpovídajících příslušné orientaci, výběr té, která nejlépe lokálně aproximuje obrazovou funkci, výběrem jedné z masek je určen i směr gradientu (orientace)
- 2. operátory založené na hledání hran v místech, kde druhá derivace obrazové funkce prochází nulou (zero-crossing), Marrův-Hildrethov operátor a Cannyho hranový detektor
- 3. operátory snažící se lokálně aproximovat obrazovou funkci poměrně jednoduchým parametrickým modelem, např. polynomem dvou proměnných



# DETEKOVÁNÍ HRAN

- **Jednoduché konvoluční masky aproximující derivace obrazové funkce:**


- **Robertsův operátor**  
konvoluční masky:

$$h_1 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \quad h_2 = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$$

velikost gradientu:

$$|g(x, y) - g(x + 1, y + 1)| + |g(x, y + 1) - g(x + 1, y)|$$

(-) velká citlivost na šum (okolí použité pro aproximaci je malé)



# DETEKOVÁNÍ HRAN

## ● Laplaceův operátor


aproximuje druhou derivaci, invariantní vůči otočení, udává velikost hrany, neudává směr

$$h_4 = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix} \quad h_8 = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -8 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

Laplacián s větší vahou pixelů blíže reprezentativnímu bodu masky, ztráta invariantnosti vůči otočení





$$h = \begin{bmatrix} 2 & -1 & 2 \\ -1 & -4 & -1 \\ 2 & -1 & 2 \end{bmatrix} \quad h = \begin{bmatrix} -1 & 2 & -1 \\ 2 & -4 & 2 \\ -1 & 2 & -1 \end{bmatrix}$$

(-) velká citlivost na šum, dvojité odezvy na hrany odpovídající tenkým liniím v obraze



# DETEKOVÁNÍ HRAN

## ● Laplaceův operátor



# DETEKOVÁNÍ HRAN


- **Operátor Prewittové**

aproximuje první derivaci, gradient je odhadován v okolí 3×3 pro osm směrů, výběr masky s největším modulem gradientu

$$h_1 = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{bmatrix} \quad h_2 = \begin{bmatrix} 0 & 1 & 1 \\ -1 & 0 & 1 \\ -1 & -1 & 0 \end{bmatrix} \quad h_3 = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} \quad \dots$$

- **Sobelův operátor**

$$h_1 = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} \quad h_2 = \begin{bmatrix} 0 & 1 & 2 \\ -1 & 0 & 1 \\ -2 & -1 & 0 \end{bmatrix} \quad h_3 = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \quad \dots$$





# DETEKOVÁNÍ HRAN

- Další směrové operátory aproximující první derivaci

- Robinsonův operátor

$$h_1 = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -2 & 1 \\ -1 & -1 & -1 \end{bmatrix} \quad h_2 = \begin{bmatrix} 1 & 1 & 1 \\ -1 & -2 & 1 \\ -1 & -1 & 1 \end{bmatrix} \quad h_3 = \begin{bmatrix} -1 & 1 & 1 \\ -1 & -2 & 1 \\ -1 & 1 & 1 \end{bmatrix} \quad \dots$$


- Kirschův operátor

$$h_1 = \begin{bmatrix} 3 & 3 & 3 \\ 3 & 0 & 3 \\ -5 & -5 & -5 \end{bmatrix} \quad h_2 = \begin{bmatrix} 3 & 3 & 3 \\ -5 & 0 & 3 \\ -5 & -5 & 3 \end{bmatrix} \quad h_3 = \begin{bmatrix} -5 & 3 & 3 \\ -5 & 0 & 3 \\ -5 & 3 & 3 \end{bmatrix} \quad \dots$$

- ...





# DETEKOVÁNÍ HRAN

- Sobelův x Kirschův operátor




# DETEKOVÁNÍ HRAN

## ● Sobelův operátor



# DETEKOVÁNÍ HRAN

- **Hrany jako průchody nulou druhé derivace obrazové funkce**
- Nevýhoda operátorů aproximujících derivaci diferencemi v malém okolí je velká závislost jejich chování na konkrétním obrázku, velikost masky musí odpovídat velikosti detailů v obraze, nejsou nezávislé na měřítku, velká citlivost na šum





# DETEKOVÁNÍ HRAN

- **Marrova teorie**
- Matematický model detekce skokových hran odpovídající neuro-fyziologickým měřením na sítnici oka, hledání polohy hrany v obraze v místě průchodu druhé derivace obrazové funkce nulou
- Druhá derivace >>> Protíná v místě hrany nulovou hodnotu, spolehlivější než hledat hrany pomocí první derivace
- Robustní počítání (odhad) druhé derivace >>> konvoluce obrazu s vyhlazujícím filtrem který požadavky (protikladné) na vyhlazující filtr:
  1. filtr má být hladký, ve frekvenčním spektru přibližně odpovídající PP >>> omezení možného počtu frekvencí, u kterých k průchodu nulou může dojít
  2. filtr by měl reagovat pouze na body z blízkého okolí hrany (přesnost lokalizace hrany v rovině)

# DETEKOVÁNÍ HRAN

- Kompromis >>> Marrova teorie
- Lineární filtr, jehož koeficienty v konvoluční masce odpovídají 2D gaussovskému rozložení:

$$G(x, y) = e^{-\frac{x^2 + y^2}{2\sigma^2}}$$

$\sigma$ ... středněkvadratická odchylka (na jak velkém okolí filtr operuje)

pixely blíže středu mají větší váhu a vliv pixelů vzdálenějších než  $3\sigma$  je zanedbatelný

- všesměrový Laplacián  $\nabla^2$  (**LoG operátor** - Laplacian of Gaussian)

$$\nabla^2(G(x, y, \sigma) * f(x, y)) = (\nabla^2 G(x, y, \sigma)) * f(x, y) \quad \text{linearita operací konvoluce a derivace}$$

- hodnoty derivace Gaussiánu  $\nabla^2 G$  lze předpočítat analyticky >>> na obrazu nezávisí

# DETEKOVÁNÍ HRAN

- $r$  ... Euklidovská vzdálenost od středu Gaussiánu (středově symetrický)  
 $x^2 + y^2 = r^2$

$$G(x, y) = e^{-\frac{x^2 + y^2}{2\sigma^2}} \rightarrow G(r) = e^{-\frac{r^2}{2\sigma^2}}$$

$$G'(r) = -\frac{1}{\sigma^2} \cdot r \cdot e^{-\frac{r^2}{2\sigma^2}}$$

$$G''(r) = \frac{1}{\sigma^2} \left( \frac{r^2}{\sigma^2} - 1 \right) \cdot e^{-\frac{r^2}{2\sigma^2}}$$

$$h(x, y) = c \left( \frac{x^2 + y^2 - \sigma^2}{\sigma^4} - 1 \right) \cdot e^{-\frac{x^2 + y^2}{2\sigma^2}}$$


$c$ ... normalizační koeficient, součet všech koeficientů v masce je 0

# DETEKOVÁNÍ HRAN

- **Aproximace operátoru LoG v masce (mexický klobouk) 5×5**

$$h(x,y) = \begin{bmatrix} 0 & 0 & -1 & 0 & 0 \\ 0 & -1 & -2 & -1 & 0 \\ -1 & -2 & 16 & -2 & -1 \\ 0 & -1 & -2 & -1 & 0 \\ 0 & 0 & -1 & 0 & 0 \end{bmatrix}$$

- Prahování LoG obrazu v intervalu hodnot blízkých k nule (slabé - nespojité hrany), lepší je použít detektor průchodů nulou, např. v masce 2 × 2 s reprezentativním bodem v levém horním rohu, Hrana se indikuje tehdy, pokud se uvnitř okna mění znaménko





# DETEKOVÁNÍ HRAN

- **Operátor DoG** (Difference of Gaussians) >>> aproximace LoG pomocí difference dvou obrazů (konvoluce s Gaussiánem o různém  $\sigma$ )
- **(-)** DoG a Log vyhlazují ostré tvary (ostré rohy se ztrácejí), spojují hrany do uzavřených křivek (hrany - "talíř špaget)
- neurofyzilogické experimenty (na kočkách) >>> sítnice lidského oka
- Shluky buněk (gangliony) velmi podobné operace jako  $\nabla^2 G$
- Každý ganglion reaguje na světelné podněty z kruhově symetrického okolí, které odpovídají  $\nabla^2 G$

# DETEKOVÁNÍ HRAN

- **Volba měřítka ve zpracování obrazů**
- Pro lokální operace >>> správně zvolit měřítko (okolí použité pro výpočet)
- U hledání hran >>> správná velikost okolí = velikost zajímavých objektů v obraze, v době předzpracování obrazu neumíme interpretovat obraz
- Kybernetika a popis složitých problémů >>> zkoumaný jev se vyjádří pomocí formálního popisu (modelu) pro každé z různých rozlišení (měřítek), studium kvalitativních změn modelu pro různá rozlišení
- Hrany >>> různá měřítko = různá středně kvadratické odchylka  $\sigma$  gaussovského filtru

- pro 1D signál: 
$$G(x, \sigma) = e^{-\frac{x^2}{2\sigma^2}}$$


funkce – prostor měřítek

$$F(x, \sigma) = f(x) * G(x, \sigma)$$

inflexní body křivky  $F(x, \sigma_0)$ , pro různé  $\sigma_0$ : 
$$\frac{\partial^2 F(x, \sigma_0)}{\partial x^2} = 0 \quad \frac{\partial^3 F(x, \sigma_0)}{\partial x^3} \neq 0$$

# DETEKOVÁNÍ HRAN

- Polohy inflexních bodů lze nakreslit v souřadnicích  $(x, \sigma)$  jako soustavu křivek, analýzou křivek >>> rozsah měřítek, při kterých nastávají zajímavé změny signálu >>> automatické nastavení měřítka lokálního operátoru, bez nutnosti interpretace obrazu



prostor měřítek pro 1D

strom intervalů

(skripta Zpracování signálů a obrazů – Sedláček, Hlaváč, FEL ČVUT)

- **Strom intervalů** >>> zobrazení kvalitativní informace, vyjadřuje strukturu signálu v pozorovaných měřítkách, intervalový strom se buduje od kořene (největší měřítko  $\sigma_{\max}$ ), prohledávání směrem k listům (směr klesajícího  $\sigma$ ), strom intervalů se větví v bodech prostoru měřítek, kde vznikají nové křivky odpovídající inflexním bodům

# DETEKOVÁNÍ HRAN

- **Cannyho hranový detektor**
- Různá rozlišení a hledání, skokovou hranu lze hledat filtrem, návrh filtru >>> úloha variačního počtu (hledání nejlepší impulsní funkce filtru)
- Detektor je optimální pro skokové hrany když:
  1. Významné hrany nesmí být přehlédnuty, na jednu hranu by neměly být vícenásobné odezvy (detekční kritérium)
  2. Rozdíl mezi skutečnou a nalezenou polohou hrany má být minimální (lokalizační kritérium)
  3. Detektor nesmí reagovat na jednu hranu v obraze vícenásobně (požadavek jedné odezvy) pro zašuměné a nehladké hrany

# DETEKOVÁNÍ HRAN

- **Zjednodušené odvození Cannyho detektoru:**
- **1.** Formulace pro 1D signál a první dvě kritéria optimalizace, využití variačního počtu s a programu pro symbolické odvozování, nalezení explicitního řešení
- **2.** Pro třetího kritérium - optimální odezva filtru numerickou optimalizací, výsledný filtr lze s aproximovat filtrací Gaussiánem  $G$  (chyba menší než 20%)
- **3.** Detektor hran zobecněn do 2D, hrana (poloha, orientace a velikost)

$$G_n = \frac{\partial G}{\partial n} = n \cdot \nabla G \quad \begin{array}{l} \text{diferenční operátor - poskytuje i orientaci hrany} \\ \text{(oproti Marrově teorii)} \end{array}$$

$$n = \frac{\nabla(G * f)}{|\nabla(G * f)|} \quad \text{robustní odhad směru gradientu}$$




$$\frac{\partial}{\partial n} G_n * f = 0$$

$$\frac{\partial^2}{\partial n^2} G * f = 0 \quad \text{nalezení lokální maxima ve směru kolmém na hranu}$$



# DETEKOVÁNÍ HRAN

- Cannyho detektor, př. čtverec 100 x 100, obvod 396 bodů?




# Ostření obrazu

- Využití gradientních operátorů pro ostření obrazu (pro člověka) větší strmost hran  
>>> zdůraznění vysokých frekvencí

$$f(x,y) = g(x,y) - C \cdot S(x,y)$$

C ... síla ostření  
S ... operátor strmosti změny obrazové funkce



# Ostření obrazu

- Ostření obrazu >>> FS >>> zdůraznění vysokých frekvencí, FT >>> lineární kombinace harmonických průběhů,  $\cos(nx)$ ,  $n = 1, 2, \dots$ , derivace >>>  $n\cos(nx)$ , čím vyšší frekvence ( $n$ ), tím větší je amplituda derivace >>> gradientní operátory zdůrazňují hrany
- Použití ostření >>> kontrastnější obraz, (sítotisk) >>> odstíny jasu se vytvářejí **polotónováním**, tj. větší či menší hustotou černých bodů >>> ostření obrazu nezbytné

